并行计算 Parallel Computing

主讲 孙经纬 2024年 春季学期

概要

- 第二篇 并行算法的设计
 - 第五章 并行算法与并行计算模型
 - 第六章 并行算法基本设计策略
 - 第七章 并行算法常用设计技术
 - 第八章 并行算法一般设计过程

第七章并行算法常用设计技术

- 7.1 划分设计技术
- 7.2 分治设计技术
- 7.3 平衡树设计技术
- 7.4 倍增设计技术
- 7.5 流水线设计技术

划分设计技术

- 朴素的并行计算思想:
 - 1. 尽可能将原始问题划分成若干独立、相等的部分
 - 2. 各部分由相应的处理器同时执行
- 均匀划分技术
- 方根划分技术
- 对数划分技术
- 功能划分技术

均匀划分技术

• 划分方法

n个元素A[1..n]分成p组,每组A[(i-1)n/p+1..in/p],i=1~p

● 示例: MIMD-SM模型上的PSRS排序 (Parallel Sorting by Regular Sampling) begin

(1)均匀划分:将n个元素A[1..n]均匀划分成p段,每个p;处理A[(i-1)n/p+1..in/p]

(2)局部排序: p_i调用串行排序算法对A[(i-1)n/p+1..in/p]排序

(3)选取样本: p_i 从其有序子序列A[(i-1)n/p+1..in/p]中选取p个样本元素

(4)样本排序:用一台处理器对p²个样本元素进行串行排序

(5)选择主元:用一台处理器从排好序的样本序列选取p-1个主元,播送给其他pi

(6)主元划分: p_i按主元将有序段A[(i-1)n/p+1..in/p]划分成p段

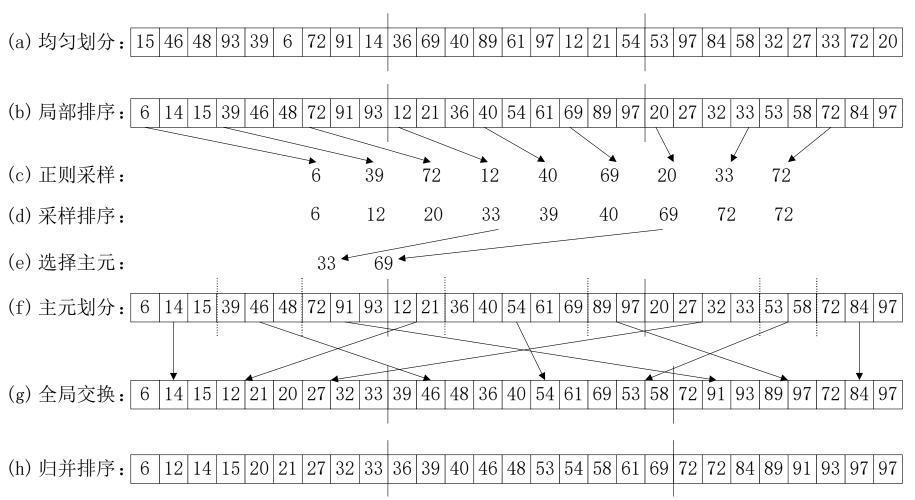
(7)全局交换: 各处理器将其有序段按段号交换到对应的处理器中

(8)归并排序: 各处理器对接收到的元素进行归并排序

end

均匀划分技术

• 例7.1 PSRS排序过程。N=27, p=3, PSRS排序如下:



划分方法
 n个元素A[1..n]分成A[(i-1)n^(1/2)+1..in^(1/2)], i=1~n^(1/2)

• 示例: Valiant归并

将两个长度分别为p,q的有序序列合并为长度p+q的有序序列通常作为其他算法中的子过程

• SIMD-CREW模型上的 $k = \lfloor \sqrt{pq} \rfloor$ Valiant归并

//有序组A[1..p]、B[1..q], (假设p<=q), 处理器数 $k = \lfloor \sqrt{pq} \rfloor$ begin

- (1) 方根划分: A,B分别按 $i[\sqrt{p}]$ 和 $j[\sqrt{q}]$ 分成若干段($i=1\sim[\sqrt{p}]$ 、 $j=1\sim[\sqrt{q}]$)
- (2)段间比较: A划分元与B划分元比较(至多 \sqrt{p}]. \sqrt{q}]对),

确定A划分元应插入B中的区段;

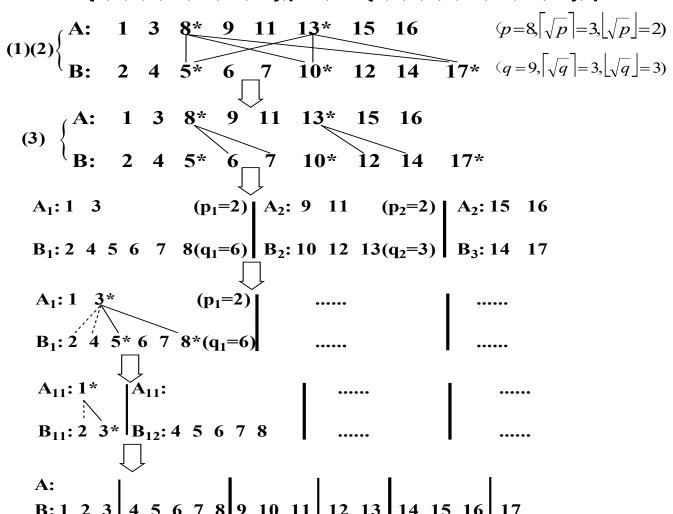
- (3)段内比较: A划分元与B相应段内元素进行比较, 并插入适当的位置;
- (4)递归归并: B按插入的A划分元重新分段,与A相应段(A除去原划分元)

构成了成对的段组,对每对段组递归执行(1)~(3),直至A

组为0时, 递归结束; 各组仍按 $k = \sqrt{pq}$ 分配处理器;

end

■ 示例: A={1,3,8,9,11,13,15,16},p=8; B={2,4,5,6,7,10,12,14,17},q=9



$$(x_1^2+x_2^2+\cdots+x_n^2)(y_1^2+y_2^2+\cdots+y_n^2) \geq (x_1y_1+x_2y_2+\cdots+x_ny_n)^2$$

柯西不等式

■算法分析

(1)算法在并行递归过程中所需的处理器数 $\leq k = \sqrt{pq}$

段间比较: \sqrt{p} 比较对数 \leq \sqrt{pq} = k;

段内比较: $\left|\sqrt{p}\right| \cdot \left|\sqrt{q}\right| - 1 \le \left|\sqrt{pq}\right| = k$

递归调用:设 A,B 分成若干子段对为(p1,q1), (p2,q2),.....

则 $\Sigma p_i \leq p$, $\Sigma q_i \leq q$, 由 Cauchy 不等式=>

$$\sum \left[\sqrt{p_i q_i} \right] \le \left[\sum \sqrt{p_i q_i} \right] \le \left[\sqrt{\sum p_i \sum q_i} \right] \le \left[\sqrt{pq} \right] = k$$

综上,整个过程可用处理器数 $k = \lfloor \sqrt{pq} \rfloor$ 完成。

(2)时间分析

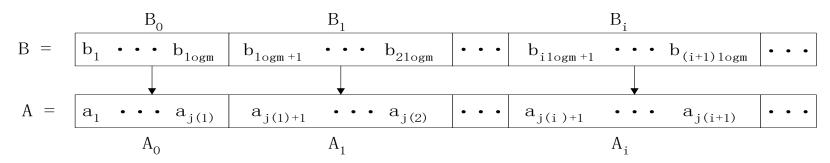
虽然每个子任务处理器 个数不一样,通过这种 方根划分,巧妙地将总 处理器数控制在k以内

记 λ_i 是第 i 次递归后的 A 组最大长度, $=>\lambda_0=p$, $\lambda_i \leq \left[\sqrt{\lambda_{i-1}}\right] \leq \cdots \leq \left[p^{2^{-i}}\right]$ 算法在 $\lambda_i = \text{常数} C$ 时终止递归,即常数 $C \leq p^{2^{-i}} \leq \text{常数} C + 1 => i \leq \log\log p + \text{常数} C_1$ 由(1)知算法中其他各步的时间为 O(1),所以 Valiant 归并算法时间

$$t_k(p,q) = O(\log \log p)$$
 $p \le q$

对数划分技术

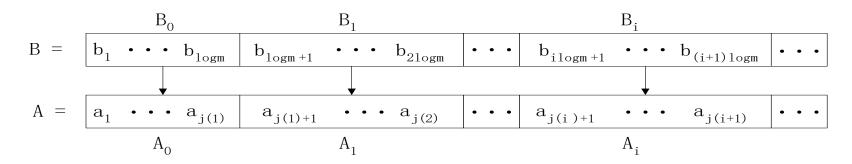
- 划分方法
 n个元素A[1..n]分成A[(i-1)logn+1..ilogn], i=1~n/logn
- 示例: PRAM-CREW上的对数划分并行归并排序 设有序组A[1..n]和B[1..m]



如果在选取A序列中的划分元素时考虑其在B序列中的全局位序,就不必对划分元素实行段间的比较

求一个元素在一个有序序列中的位置,可以使用二分查找

对数划分技术



令j[i]=rank(b_{ilogm}:A)为b_{ilogm}在A中的位序,即A中小于等于b_{ilogm}的元素数

例: A=(4,6,7,10,12,15,18,20), B=(3,9,16,21) n=8, m=4 =>logm=log4=2

 $=> j[1]=rank(b_{logm}:A)=rank(b_2:A)=rank(9:A)=3, j[2]=...=8$

 B_0 : 3, 9 B_1 : 16, 21

 A_0 : 4, 6, 7 A_1 : 10, 12, 15, 18, 20

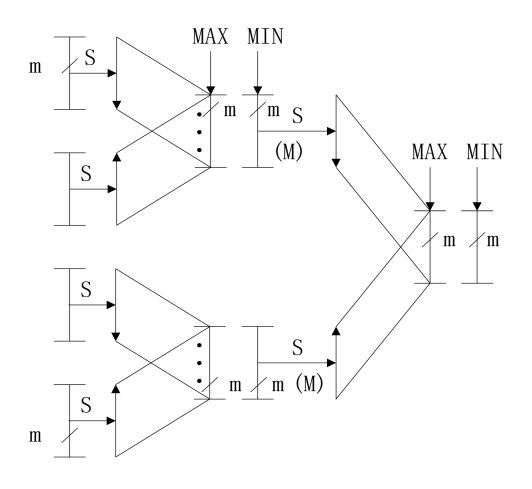
A和B归并化为 (A_0, B_0) 和 (A_1, B_1) 的归并

功能划分技术 (???)

- 划分方法 n个元素A[1..n]分成等长的p组,每组满足某种特性。
- 示例: (m, n)选择问题(求出n个元素中前m个最小者)
 - 功能划分:要求每组元素个数必须大于等于m;
 - 算法: p194算法7.4 输入: A=(a₁,...,a_n); 输出: 前m个最小者;
 Begin
 - (1) 功能划分: 将A划分成g=n/m组, 每组含m个元素;
 - (2) 局部排序: 使用双调排序网络将各组并行进行排序;
 - (3) 构造双调:每两个有序子序列合并成一个双调序列;
 - (4) 两两比较:根据Batcher定理,将双调序列划分为MIN, MAX
 - (5) 排序-比较:对各个MIN序列,重复执行第(2)-(4)步,直至 选出m个最小者。

End

功能划分技术



(m, n)选择过程, S表示排序, M表示归并

第七章并行算法常用设计技术

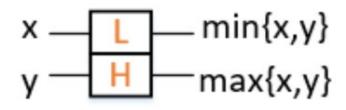
- 7.1 划分设计技术
- 7.2 分治设计技术
- 7.3 平衡树设计技术
- 7.4 倍增设计技术
- 7.5 流水线设计技术

并行分治设计步骤

- 将输入划分成若干个规模相等的子问题;
- 同时(并行地)递归求解这些子问题;
- 并行地归并子问题的解, 直至得到原问题的解。

• Batcher比较器

在两个输入端给定输入x,y,再在两个输出端输出max{x,y}和min{x,y}



- 双调序列(Bitonic sequence)
- 一个序列 $x_0, x_1, ..., x_{n-1}$ 是双调序列,如果:
 - (1)存在一个x_k (0≤k≤n-1), 使得x₀≥...≥x_k≤...≤x_{n-1}成立; 或者
 - (2)序列能够循环移位满足条件(1)

(1,3,5,7,8,6,4,2,0)

(8,7,6,4,2,0,1,3,5)

(1,2,3,4,5,6,7,8)

以上都是双调序列

"山谷"和"山峰"都是双调序列



• Batcher定理

给定双调序列($x_0,x_1,...,x_{2n-1}$), 令 s_i =min{ x_i, x_{i+n} }和 I_i =max{ x_i,x_{i+n} },则小数序列($s_0,s_1,...,s_{n-1}$)和大数序列($I_0,I_1,...,I_{n-1}$)满足:

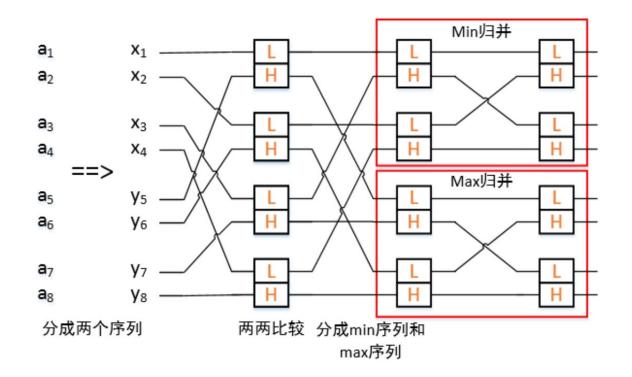
- $(1) s_i \le l_j \quad (0 \le i, j \le n-1)$
- (2)小数和大数序列仍是双调序列
- 直观理解:

由于可以循环移位,所以"中间" 其实可以是任意位置

将任意一个长为2n的双调序列A从中间切成两半,分成等长的两个序列s和I,然后s和I相同位置的元素s_i与I_i比较,小的放到Min序列,大的放到Max序列。由此得到的Max序列和Min序列也是双调序列,且Min序列的每个元素小于或等于Max序列的每个元素。

• 基于Batcher定理的双调归并网络

将任意一个长为2n的双调序列划分成Min序列和Max序列,再分别对Min序列和Max序列进行划分,以此类推,直到n=1。最后再将所有含两个元素的子序列归并成完全有序的序列



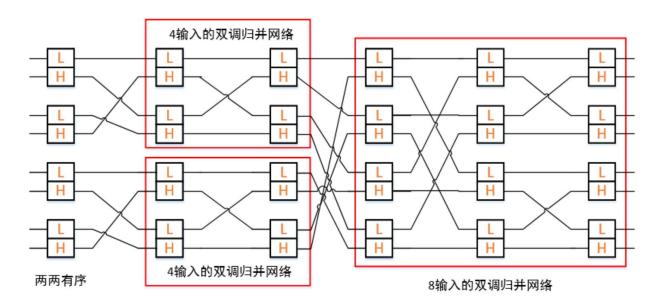
20

• 双调归并网络

```
输入: 双调序列X=(x<sub>0</sub>,x<sub>1</sub>,...,x<sub>n-1</sub>)
                                                    注意! 双调归并网络将一个
输出: 非降有序序列Y=(y<sub>0</sub>,y<sub>1</sub>,...,y<sub>n-1</sub>)
                                                    双调序列转换为有序序列
Procedure BITONIC MERG(x)
Begin
 (1)for i=0 to n/2-1 par-do
    (1.1) s_i = min\{x_i, x_{i+n/2}\}
    (1.2) I_i = \max\{x_i, x_{i+n/2}\}
    end for
 (2)Recursive Call:
     (2.1)BITONIC_MERG(MIN=(s_0,...,s_{n/2-1}))
     (2.2)BITONIC_MERG(MAX=(I_0,...,I_{n/2-1}))
 (3) output sequence MIN followed by sequence MAX
End
```

双调排序网络通过调用双调归并网络, 实现对**任意序列**的并行排序

- 双调排序网络 —— 给定2n长度任意序列:
 - 1. 两两比较,形成n个2元素有序序列
 - 2. 每两个2元素有序序列,可构造成一个4元素双调序列
 - 3. 使用双调归并网络,将4元素双调序列变为有序序列
 - 4. 每两个4元素有序序列,可构造成一个8元素双调序列
 - 5. 使用双调归并网络,将8元素双调序列变为有序序列
 - 6. 按步骤2-5类推,直到将2n个元素变为有序序列



第七章并行算法常用设计技术

- 7.1 划分设计技术
- 7.2 分治设计技术
- 7.3 平衡树设计技术
- 7.4 倍增设计技术
- 7.5 流水线设计技术

平衡树设计步骤

• 设计思想

以树的叶结点为输入,中间结点为处理结点,由叶向 根或由根向叶逐层进行并行处理。

- 示例
 - 求最大值
 - 计算前缀和

求最大值

• 算法7.8: SIMD-TC(SM)上求最大值算法 TC: 树形连接网络

Begin K=0 for k=m-1 to 0 do for $j=2^k$ to $2^{k+1}-1$ par-do $A[j]=max{A[2j], A[2j+1]}$ end for end for K=m-2 end K=m-1 $P_{n/2}$ P_2 $-P_{n/2-1}A_{n-2}$ • 时间分析 $t(n)=m\times O(1)=O(log n)$ p(n)=n/2

求最大值

CRCW模型上常常能构造出这种 "抽象的"常数时间算法,然而真 实机器其实很难满足CRCW

• SIMD-CRCW上常数时间求最大值算法

```
算法 SIMD-CRCW上枚举算法
//输入A[1..p], p个不同元素
//B[1..p][1..p],M[1..p]为中间处理用的布尔数组,如果<math>M[i] = 1,则A[i]为最大值
begin
  (1)for 1≤i, j≤p par-do //工作量O(p²); 时间O(1),因为允许同时读
     if A[i] \ge A[j] then B[i, j] = 1 else B[i, j] = 0
     end if
   end for
 (2)for 1≤i≤p par-do //工作量O(p²); 时间O(1),因为允许同时写
     M[i]=B[i,1] \wedge B[i,2] \wedge ... \wedge B[i,p]
                                                 T(n)=O(1)
   end for
                                                \mathbf{W}(n)=\mathbf{O}(p^2)
                                                 可以用p<sup>2</sup>个处理器实现
                   M[i]=1
end
                                                 速度虽快,但不是W最优
                   for 1≤j≤p par-do
                     if B[i, i] = 0 then M[i] = 0
```

• 问题定义

```
n个元素\{x_1, x_2, ..., x_n\},前缀和是n个部分和: S_i = x_1 * x_2 * ... * x_i,1 \le i \le n 这里*可以是 + 或×
```

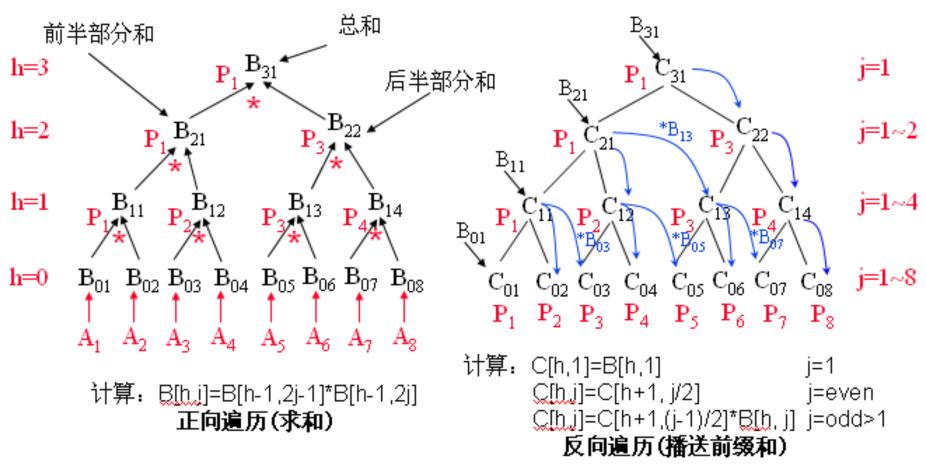
- 串行算法: S_i=S_{i-1}*x_i 计算时间为 O(n)
- 并行算法: p199算法7.9 SIMD-TC上非递归算法
 令A[i]=x_i, i=1~n,

B[h,j]和C[h,j]为辅助数组(h=0~logn, j=1~n/2h)

数组B记录由叶到根正向遍历树中各结点的信息(求和)

数组C记录由根到叶反向遍历树中结点的信息(播送前缀和)

• 例: n=8, p=8, C01~C08为前缀和



■ SIMD-SM上非递归算法

```
begin

(1)for j=1 to n par-do //初始化

B[0,j]=A[j]

end if

(2)for h=1 to logn do //正向遍历

for j=1 to n/2h par-do

B[h,j]=B[h-1,2j-1]*B[h-1,2j]

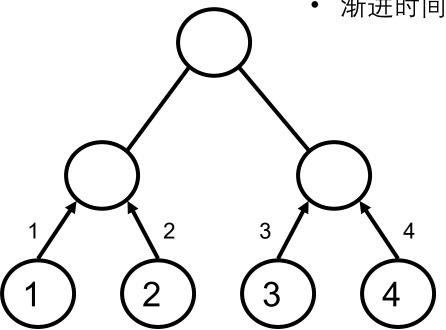
end for

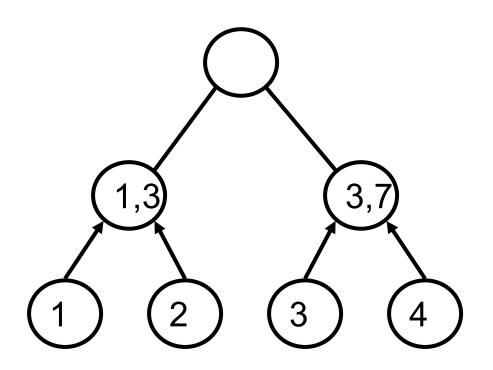
end for
```

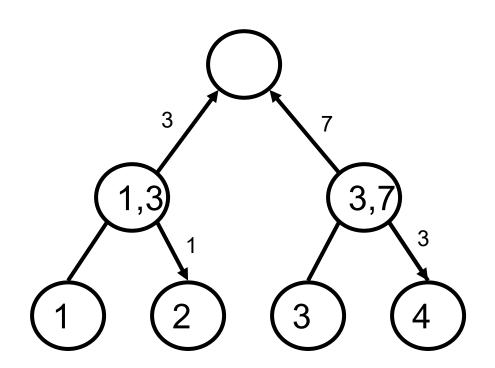
时间分析:

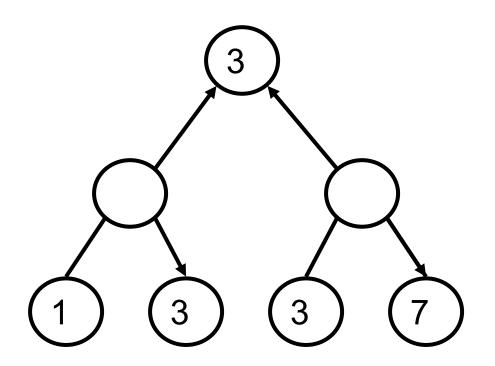
另一种实现方式:

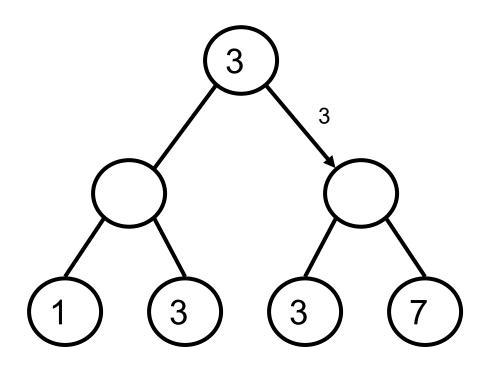
- 不必等正向遍历完成
- 部分结果可以提前开始反向遍历
- 渐进时间复杂度一样

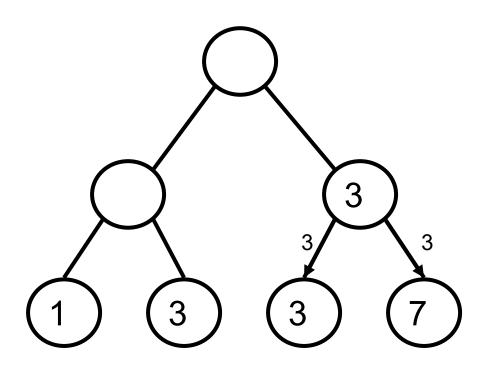


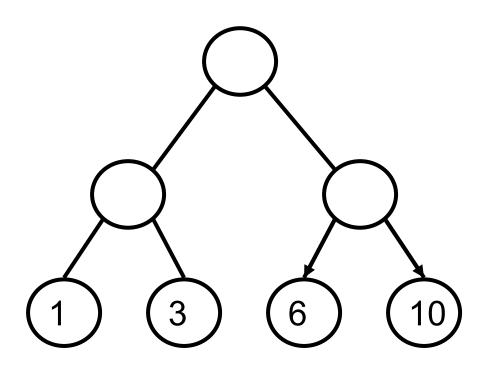












计算前缀和

Properties:

• time: 2 log *n*

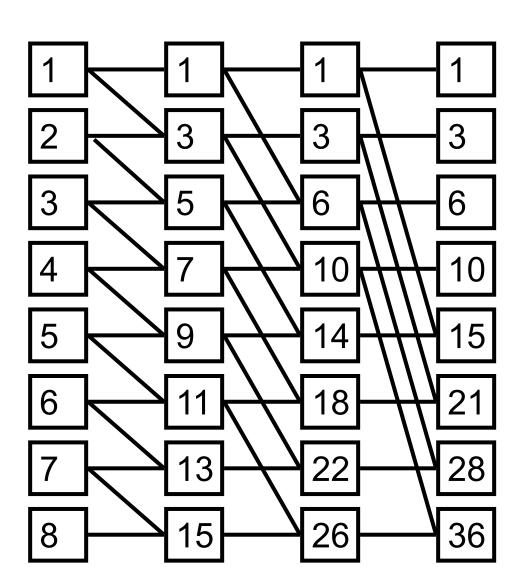
• processors: 2n-1

• cost $O(n \log n)$

Comparison with PRAM algorithm

- asymptotically equivalent
- in practice, less efficient
 - weaker model

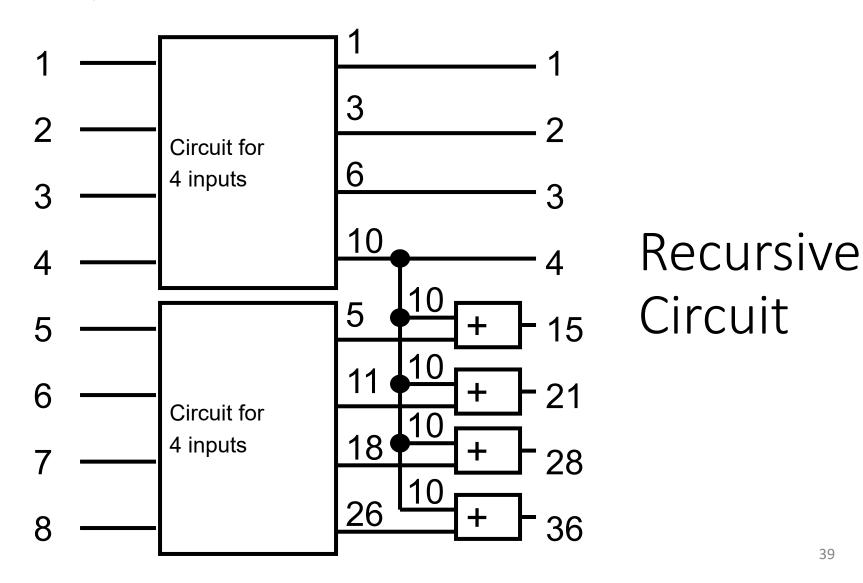
计算前缀和



depth (time) = 3 complexity (cost) = 3×8 = 24

Specialized Circuit

计算前缀和



第七章并行算法常用设计技术

- 7.1 划分设计技术
- 7.2 分治设计技术
- 7.3 平衡树设计技术
- 7.4 倍增设计技术
- 7.5 流水线设计技术

倍增设计技术

■ 设计思想

- 又称指针跳跃(pointer jumping)技术,特别适合于处理链表或有向树之类的数据结构;
- 当递归调用时,所要处理数据之间的距离逐步加倍, 经过k步后即可完成距离为2^k的所有数据的计算。

■ 示例

- 表序问题
- 求森林的根

表序问题

■ 问题描述

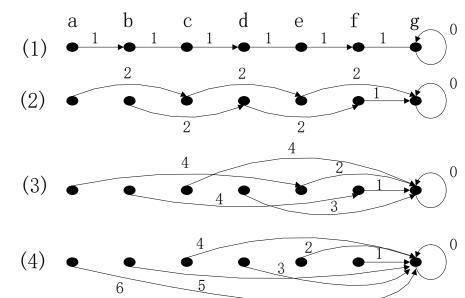
n个元素的列表L,求出每个元素在 L中的位序rank(k),

rank(k)可视为元素k至表尾的距离;

■ 示例: n=7

(1)p[a]=b, p[b]=c, p[c]=d, p[d]=e, p[e]=f, p[f]=g, p[g]=g r[a]=r[b]=r[c]=r[d]=r[e]=r[f]=1, r[g]=0

- (2)p[a]=c, p[b]=d, p[c]=e, p[d]=f, p[e]=p[f]=p[g]=g r[a]=r[b]=r[c]=r[d]=r[e]=2, r[f]=1, r[g]=0
- (3)p[a]=e, p[b]=f, p[c]=p[d]=p[e]=p[f]=p[g]=g r[a]=4, r[b]=4, r[c]=4, r[d]=3, r[e]=2, r[f]=1, r[g]=0
- (4)p[a]=p[b]=p[c]=p[d]=p[e]=p[f]=p[g]=g r[a]=6, r[b]=5, r[c]=4, r[d]=3, r[e]=2, r[f]=1, r[g]=0



表序问题

■ 教材P200算法7.10

```
(1) par-do:初始化p[k]和distance[k]    //O(1)
```

(2)执行
$$\lceil \log n \rceil$$
 次 //O($\log n$)

(2.1) for all k par-do
$$//O(1)$$

如果k的后继不等于k的后继之后继,则

- (i) distance[k]= distance[k]+ distance[p[k]]
- (ii) p[k]=p[p[k]]
- (2.2) for all k par-do

$$rank[k]=distance[k]$$
 //O(1)

运行时间: t(n)=O(logn) p(n)=n

求森林的根

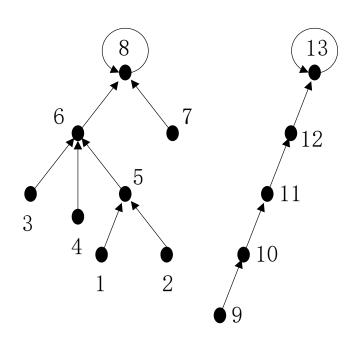
■ 问题描述

一组有向树F中, 如果<i, j>是F中的一条弧,则p[i]=j(即j是i的双亲); 若i为根,则p[i]=i。求每个结点j(j=1~n)的树根s[j].

■ 示例

初始时

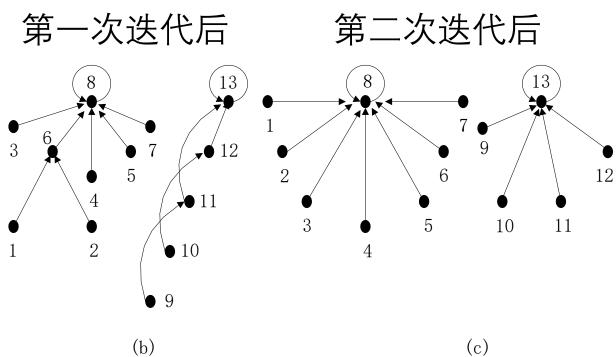
p[1]=p[2]=5 p[3]=p[4]=p[5]=6 p[6]=p[7]=8 p[8]=8 P[9]=10 p[10]=11 p[11]=12 p[12]=13 p[13]=13 s[i]=p[i]



(a)

求森林的根

■ 示例



■ 算法: 教材P202算法7.11

■ 运行时间: t(n)=O(logn) W(n)=O(nlogn)

第七章并行算法常用设计技术

- 7.1 划分设计技术
- 7.2 分治设计技术
- 7.3 平衡树设计技术
- 7.4 倍增设计技术
- 7.5 流水线设计技术

流水线设计技术

■ 设计思想

- 将算法流程划分成p个前后衔接的任务片断,每个任务片断的输出作为下一个任务片断的输入;
- 所有任务片断按同样的速率产生出结果。

■ 评注

- 流水线技术是一种广泛应用在并行处理中的技术;
- 脉动算法(Systolic algorithm)是其中一种流水线技术;
- 近年最典型的软件流水线应用: DNN training

5-point DFT的计算

■ n点离散傅里叶变换将给定的序列($a_0, a_1, ... a_{n-1}$)变换为序列($b_0, b_1, ... b_{n-1}$):

$$b_{j} = \sum_{k=0}^{n-1} a_{k} \omega^{kj}, 0 \le j \le n-1$$

其中
$$\omega = e^{2\pi i/n}$$

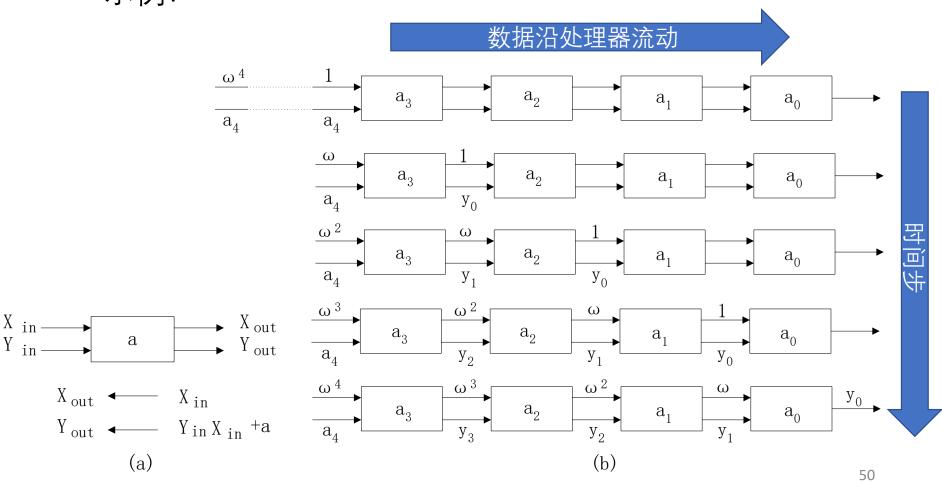
5-point DFT的计算

■ 5-point DFT的计算。应用Horner法则:

$$\begin{cases} y_0 = b_0 = a_4 \omega^0 + a_3 \omega^0 + a_2 \omega^0 + a_1 \omega^0 + a_0 \\ y_1 = b_1 = a_4 \omega^4 + a_3 \omega^3 + a_2 \omega^2 + a_1 \omega^1 + a_0 \\ y_2 = b_2 = a_4 \omega^8 + a_3 \omega^6 + a_2 \omega^4 + a_1 \omega^2 + a_0 \\ y_3 = b_3 = a_4 \omega^{12} + a_3 \omega^6 + a_2 \omega^4 + a_1 \omega^2 + a_0 \\ y_4 = b_4 = a_4 \omega^{16} + a_3 \omega^6 + a_2 \omega^4 + a_1 \omega^2 + a_0 \end{cases} \Rightarrow \begin{cases} y_0 = (((a_4 \omega^0 + a_3)\omega^0 + a_2)\omega^0 + a_1)\omega^0 + a_0 \\ y_1 = (((a_4 \omega^1 + a_3)\omega^1 + a_2)\omega^1 + a_1)\omega^1 + a_0 \\ y_2 = (((a_4 \omega^2 + a_3)\omega^2 + a_2)\omega^2 + a_1)\omega^2 + a_0 \\ y_3 = (((a_4 \omega^3 + a_3)\omega^3 + a_2)\omega^3 + a_1)\omega^3 + a_0 \\ y_4 = (((a_4 \omega^4 + a_3)\omega^4 + a_2)\omega^4 + a_1)\omega^4 + a_0 \end{cases}$$

5-point DFT的计算

■ 示例:



二维求和阵列

■ 用多线程流水方法计算下面阵列

$$A: \begin{pmatrix} 0 & 1 & 3 & 6 & 10 & 15 & 21 \\ 1 & 2 & 5 & 11 & 21 & 36 & 57 \\ 3 & 5 & 10 & 21 & 42 & 78 & 135 \\ 6 & 11 & 21 & 42 & 84 & 162 & 297 \end{pmatrix}$$

计算公式如下:

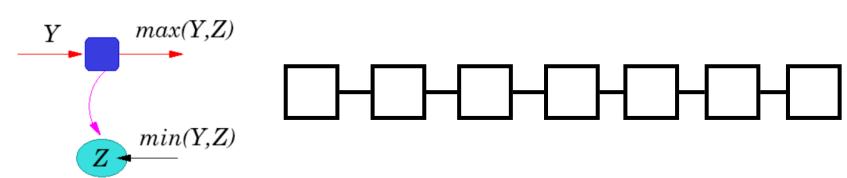
$$A[i, j] = \begin{cases} 0 & if \ i = 0 \ and \ j = 0 \\ A[0, j-1] + j & if \ i = 0 \ and \ j > 0 \\ A[i-1, 0] + i & if \ i > 0 \ and \ j = 0 \\ A[i-1, j] + A[i, j-1] & other \end{cases}$$

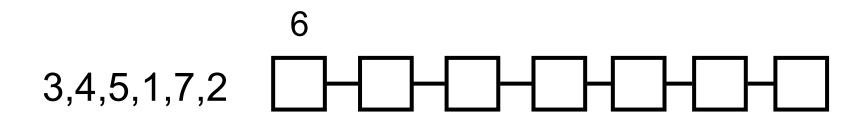
二维求和阵列

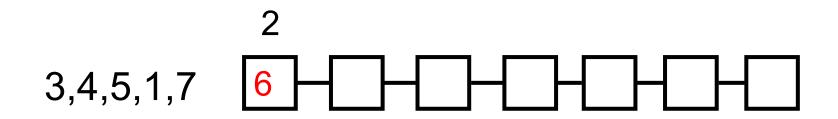
计算公式:

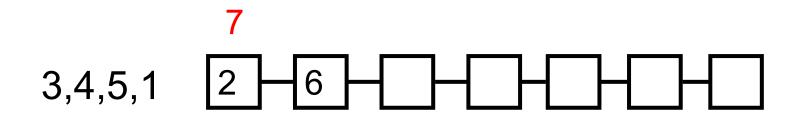
$$\text{data}[T_{i}, S_{j}] = \begin{cases} 0 & \text{if } i = 0 \text{ and } j = 0 \\ \text{data}[T_{0}, S_{j-1}] + j & \text{if } i = 0 \text{ and } j > 0 \\ \text{data}[T_{i-1}, S_{0}] + i & \text{if } i > 0 \text{ and } j = 0 \\ \text{data}[T_{i-1}, S_{j}] + \text{data}[T_{i}, S_{j-1}] & \text{other} \end{cases}$$

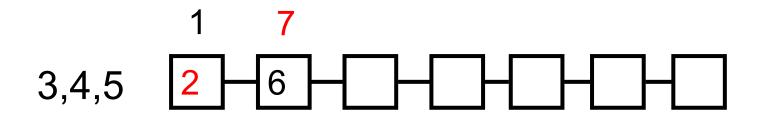
- 一维线性阵列上的心动排序算法
 - 每个处理器存储自己见过的最小数字
 - 每个处理器初始存储值为无穷大
 - 每当从左邻居接收到Y,留下Y和自己存储的Z中的较小值,将较大值传给右邻居。

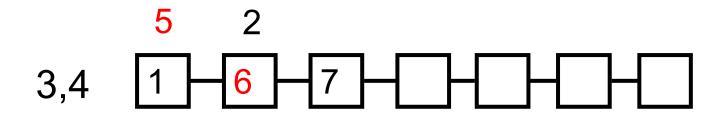


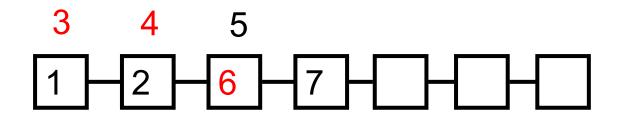


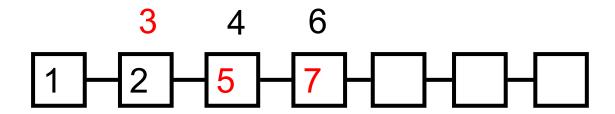


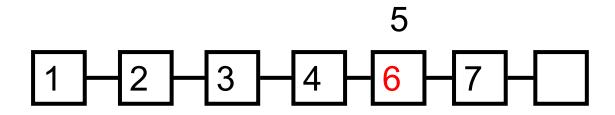


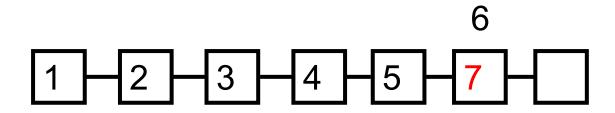




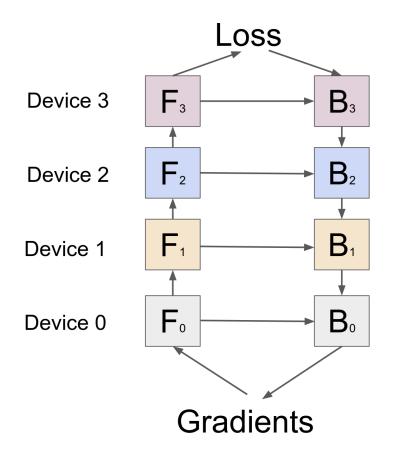




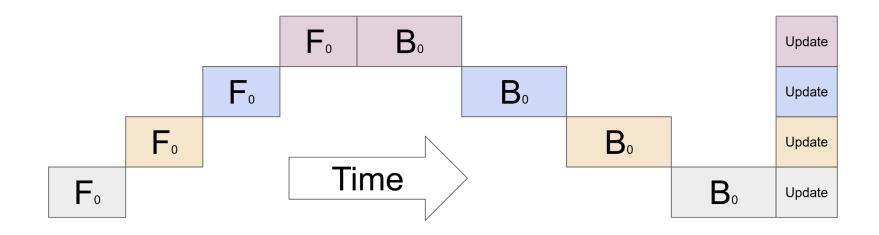




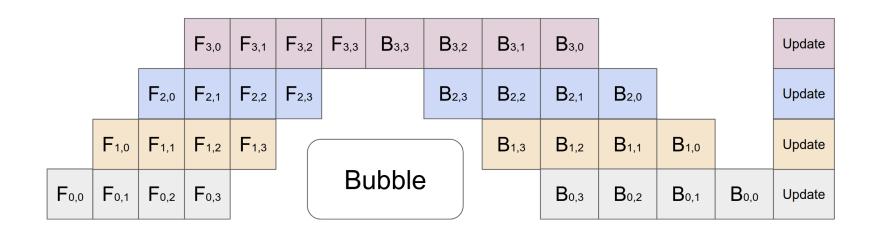




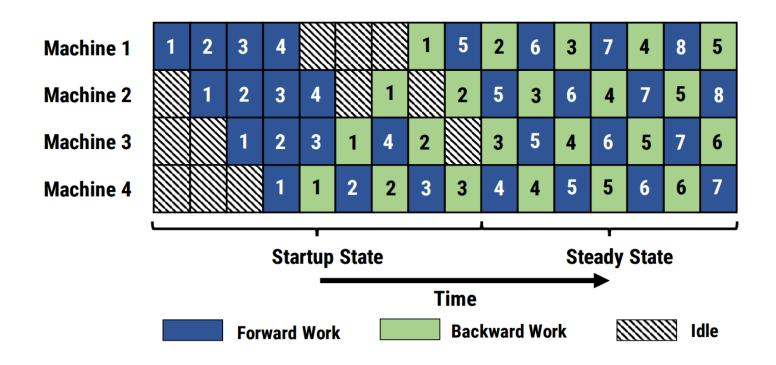
DNN训练过程中前向与后向传播的数据依赖



每个设备负责一层,由于数据依赖导致无法并行



将每一层划分为更小的任务执行单元,获得流水线并行加速,但仍有不少气泡



一种紧凑的Pipeline设计

Deepak Narayanan, Aaron Harlap, Amar Phanishayee, Vivek Seshadri, Nikhil R. Devanur, Gregory R. Ganger, Phillip B. Gibbons, Matei Zaharia: PipeDream: generalized pipeline parallelism for DNN training. SOSP 2019: 1-15

Bubble

X X Forward and backward passes of *model replicas* **0-1** for micro-batch **x**Y Y Forward and backward passes of *model replicas* **2-3** for micro-batch **y**

model replicas 0-3 flush stage4 stage7 stage3 PO stageO P1 stage1 stage5 stage6 stage2 stage6 stage5 P2 stage2 stage1) P3 stage3 (stage7) stage4 stage0 6 6 stage0 stage3 P4 stage4 stage7 P5 stage5 stage1 stage2 (stage6) P6 stage6 stage2 stage1 stage5 stage3 stage0 P7 stage7 stage4

一种更紧凑的Pipeline设计